

Un pipeline bioinformatique léger et utilisable hors ligne pour la surveillance de la résistance à l'artémisinine kelch13 (K13) chez *Plasmodium falciparum* en Afrique de l'Ouest : double validation sur des séquences simulées et cliniques

Boris Djagou¹

¹Igbega X Bioinformatics Group, Cotonou, Bénin

Dépôt du code : <https://github.com/ShegouB/artemisinin-resistance>

Contact : djagouboris@gmail.com

Abstract

Contexte : Les thérapies combinées à base d'artémisinine (ACT) constituent le pilier du traitement du paludisme à *Plasmodium falciparum* en Afrique de l'Ouest [1, 2]. Cependant, la propagation mondiale de la résistance à l'artémisinine, marquée moléculairement par des mutations non synonymes dans le domaine propeller du gène kelch13 (K13) de *P. falciparum*, représente une menace majeure de santé publique [3]. Le déploiement d'outils bioinformatiques de surveillance légers et utilisables hors ligne dans les laboratoires nationaux de référence ouest-africains aux ressources limitées est essentiel pour préserver l'efficacité thérapeutique régionale des ACT.

Méthodes : Nous avons développé un pipeline open-source en Python qui récupère la séquence de référence K13 de la souche 3D7, construit une base de données BLAST locale, effectue un traitement des séquences tenant compte de l'alignement, et dépiste les neuf mutations de résistance validées par l'Organisation Mondiale de la Santé (OMS). Pour évaluer la performance diagnostique, un protocole de double validation a été mis en place. Premièrement, une validation interne a été réalisée sur 30 séquences ouest-africaines simulées *in silico* contenant des mutations ponctuelles validées, introduites aléatoirement. Deuxièmement, une validation externe a été conduite sur un panel clinique enrichi géographiquement de 66 séquences K13 ouest-africaines réelles (représentant le Bénin, le Ghana, le Niger, le Nigeria et le Sénégal), récupérées de manière programmatique depuis NCBI GenBank [4, 5, 6, 7]. Afin de traiter de façon robuste les amplicons Sanger tronqués et de gérer les séquences

en brin inverse sans intervention manuelle, un algorithme de traduction à 6 cadres, reposant sur une heuristique de score par correspondance de peptides de 5 résidus (5-mer), a été implémenté.

Résultats : Sur le panel synthétique, le pipeline a correctement classé les 30 isolats, obtenant une sensibilité et une spécificité de détection des mutations de 100 % (30/30 isolats), sans aucun faux positif ni faux négatif. Sur le panel clinique, l'algorithme heuristique à 6 cadres a traduit et aligné avec succès les 66 séquences, résolvant les anomalies d'alignement antérieures liées aux décalages de cadre et aux brins inverses (pourcentages N/A), avec des identités BLASTP allant de 91,8 % à 100,0 %. Le pipeline a classé 65 isolats cliniques comme sauvages (wild-type) et a automatiquement détecté la présence du marqueur de résistance Y493H, validé par l'OMS, dans un isolat clinique du nord du Ghana (accession OQ102665), reproduisant avec une forte concordance des résultats cliniques déjà publiés [5].

Conclusions : Cette étude valide un pipeline léger, hautement résilient et entièrement open-source, capable de traiter des séquences Sanger cliniques dans des conditions de terrain réalistes. En dissociant la traduction et l'analyse des séquences des coordonnées absolues rigides, ce pipeline permet une surveillance hors ligne de l'émergence de la résistance à l'artémisinine au Bénin et dans l'ensemble de la région ouest-africaine.

Mots-clés : *Plasmodium falciparum* ; kelch13 ; résistance à l'artémisinine ; surveillance moléculaire ; BLAST ; pipeline bioinformatique ; Afrique de l'Ouest ; Bénin.

1. Introduction

Le paludisme demeure une cause majeure de morbidité et de mortalité en Afrique subsaharienne, *Plasmodium falciparum* étant responsable de la grande majorité des cas cliniques graves et des décès sur le continent. Depuis plus de deux décennies, les thérapies combinées à base d'artémisinine (ACT) constituent le traitement de première ligne incontesté du paludisme à *falciparum* non compliqué en Afrique de l'Ouest. L'efficacité thérapeutique de ces combinaisons dépend toutefois fortement de la clairance parasitologique rapide induite par le composant artémisinine, à action courte.

La sensibilité clinique réduite aux dérivés de l'artémisinine, caractérisée par un retard de la clairance parasitaire, est associée moléculairement à des polymorphismes nucléotidiques simples (SNP) non synonymes dans le domaine propeller du gène kelch13 de *P. falciparum* (K13, identifiant du gène : PF3D7_1343700) [1]. Un panel spécifique de ces substitutions d'acides aminés a été formellement validé par l'Organisation Mondiale de la Santé (OMS) comme marqueurs moléculaires de résistance partielle confirmée ou candidate à l'artémisinine [1, 2]. Bien que ces mutations soient apparues et se soient propagées de façon clonale principalement dans la sous-région du Grand Mékong, en Asie du Sud-Est, l'émergence indépendante *de novo* et l'expansion clonale ultérieure de la mutation K13 R561H au Rwanda et en RD Congo [3], ainsi que l'apparition de marqueurs candidats dans la Corne de l'Afrique, indiquent que les populations parasitaires africaines sélectionnent activement des allèles de résistance sous la pression médicamenteuse.

La surveillance moléculaire du gène K13 en Afrique de l'Ouest est habituellement assurée par les laboratoires nationaux de référence, généralement via une amplification

par PCR suivie d'un séquençage Sanger du domaine propeller. Cependant, la conversion de ces données brutes de séquençage en rapports de résistance structurés se heurte à d'importants obstacles logistiques. Les petits laboratoires manquent souvent d'un accès internet stable, ce qui les contraint à dépendre de consortiums internationaux distants [4] ou de logiciels propriétaires coûteux et peu pratiques pour réaliser des alignements curés manuellement. De plus, les dépôts de séquences dans les bases de données publiques telles que NCBI GenBank consistent fréquemment en séquences Sanger partielles, dont certaines sont déposées sous forme de séquences en brin inverse-complémentaire par rapport au brin codant [5, 6]. La traduction naïve de ces lectures en brin inverse ou de ces séquences tronquées génère des décalages de cadre de lecture et des codons stop prématurés, entraînant des échecs d'alignement dans les pipelines automatisés standards.

Pour répondre à ces défis, nous avons conçu, implémenté et validé un pipeline Python open-source, léger et déployable hors ligne. Ce pipeline utilise une heuristique de traduction à 6 cadres résiliente et un parcours de coordonnées tenant compte de l'alignement pour dépister les mutations de résistance dans les isolats K13 ouest-africains. Nous rapportons ici une double validation complète du pipeline, à la fois sur des jeux de données simulés (validation interne) et sur un panel clinique géographiquement diversifié de 66 séquences ouest-africaines réelles (validation externe) récupérées depuis GenBank [4, 5, 6, 7].

2. Matériel et méthodes

2.1 Récupération de la séquence de référence

La séquence protéique de référence pleine longueur de K13 chez la souche 3D7 de *P. falciparum* (726 acides aminés ; accession NCBI RefSeq XP_001350158.1) a été récupérée de manière programmatique via le module BioPython Bio.Entrez. Une base de données BLAST protéique locale a été construite à partir de cette unique séquence de référence à l'aide de la commande `makeblastdb` de la suite NCBI BLAST+ (v2.12.0), avec la configuration `-dbtype prot`.

2.2 Panel des mutations de résistance

Neuf mutations du domaine propeller de K13, validées par l'OMS, ont été compilées dans une table de référence (Tableau 1), indiquant la position de référence (numérotée à partir de 1), le résidu sauvage, le résidu muté et le contexte géographique principal rapporté. Les neuf positions se situent toutes dans le domaine propeller de Kelch (résidus approximatifs 440–680).

2.3 Jeu de données de validation simulée (interne)

Pour évaluer la sensibilité et la spécificité logiques du module de détection des mutations, un panel synthétique de 30 isolats fictifs a été construit *in silico*. Les séquences ont été générées en attribuant à chaque enregistrement un pays d'origine ouest-africain simulé au hasard (Bénin, Burkina Faso, Côte d'Ivoire, Ghana, Mali, Nigeria, Sénégal). Des mutations

Table 1: Mutations de résistance du domaine propeller de kelch13 validées par l'OMS.

Mutation	Position	Sauvage	Mutant	Contexte principal rapporté
F446I	446	Phe (F)	Ile (I)	Myanmar / Asie du Sud-Est [1]
N458Y	458	Asn (N)	Tyr (Y)	Asie du Sud-Est [2]
M476I	476	Met (M)	Ile (I)	Asie du Sud-Est [1]
Y493H	493	Tyr (Y)	His (H)	Asie du Sud-Est [1, 5]
R539T	539	Arg (R)	Thr (T)	Asie du Sud-Est / émergent en Afrique [2]
I543T	543	Ile (I)	Thr (T)	Asie du Sud-Est [2]
P553L	553	Pro (P)	Leu (L)	Asie du Sud-Est [1]
R561H	561	Arg (R)	His (H)	Rwanda / RD Congo (émergent en Afrique) [3]
C580Y	580	Cys (C)	Tyr (Y)	Mondial / marqueur dominant [1, 2]

ponctuelles issues du Tableau 1 ont été introduites dans 23,3 % des séquences (7/30), tandis que les 76,7 % restants (23/30) ont conservé la séquence de référence non modifiée. Les mutations de référence (vérité terrain) ont été stockées séparément dans un fichier tabulé et masquées au pipeline lors de l'exécution.

2.4 Jeu de données cliniques réel multi-pays (externe)

Pour évaluer la spécificité clinique du pipeline dans des conditions de surveillance réalistes, nous avons constitué un panel géographique enrichi de 66 séquences cliniques réelles d'Afrique de l'Ouest, téléchargées de manière programmatique depuis NCBI GenBank. Le panel était composé du Bénin ($n = 20$; accessions MN072940 à MN072959), du Niger ($n = 15$; accessions MZ364160 à MZ364174), du Nigeria ($n = 15$; accessions MT113570 à MT113584), du Ghana ($n = 15$; accessions OQ102653 à OQ102667) et du Sénégal ($n = 1$; accession MH464876).

Pour garantir que le panel clinique ne contenait que des séquences authentiquement ouest-africaines, le script a analysé les métadonnées GenBank de façon programmatique. Premièrement, le pays d'origine était extrait du qualificatif `/country` de la fonctionnalité source de l'enregistrement GenBank. Deuxièmement, en l'absence de ce qualificatif, le script effectuait une analyse sémantique de la description GenBank (détection des noms de pays ouest-africains). Troisièmement, si les deux méthodes échouaient, l'attribution du pays reposait sur une table de correspondance déterministe liée au préfixe de l'accession. Toute séquence récupérée dont l'origine se situait hors des frontières ouest-africaines prédéfinies était automatiquement exclue de l'analyse.

2.5 Algorithme heuristique de traduction à 6 cadres par correspondance de 5-mers

Les fichiers FASTA consensus issus du séquençage Sanger contiennent souvent des séquences partielles, sont dépourvus d'annotation de cadre de lecture ouvert, ou ont été séquencés à partir d'amorces inverses. Pour contourner un alignement et une correction de phase manuels fastidieux, nous avons conçu une heuristique de traduction à 6 cadres.

Soit N la séquence nucléotidique brute et R la séquence protéique de référence de 726 résidus de K13 chez 3D7. Le script évalue à la fois le brin direct N_{fwd} et son

inverse-complémentaire $N_{\text{rev}} = \text{reverse_complement}(N)$. Pour chaque brin, trois cadres de traduction (0, 1, 2) sont générés, produisant six séquences protéiques candidates $T_{s,f}$ où $s \in \{\text{fwd}, \text{rev}\}$ et $f \in \{0, 1, 2\}$:

$$T_{s,f} = \text{translate}\left(N_s\left[f : 3 \times \left\lfloor \frac{|N_s| - f}{3} \right\rfloor\right]\right) \quad (1)$$

Pour classer ces candidats et sélectionner le cadre de lecture ouvert (ORF) codant correct, nous calculons un score de correspondance $S(T_{s,f})$ fondé sur l'occurrence de peptides de 5 résidus (5-mers) au sein de la séquence de référence R :

$$S(T_{s,f}) = \sum_{i=1}^{|T_{s,f}|-4} \mathbb{I}(T_{s,f}[i : i+5] \subset R) \quad (2)$$

où $\mathbb{I}(\cdot)$ est une fonction indicatrice qui retourne 1 si la sous-chaîne de 5-mer est présente dans R , et 0 sinon. Une longueur de peptide de 5 résidus (5-mer) a été choisie empiriquement comme le meilleur compromis pour maximiser la spécificité du score sur des amplicons courts et fortement conservés, tout en évitant le bruit de fond causé par de courts motifs répétés simples. Afin d'empêcher le traitement de séquences hors cible non homologues, un seuil de score minimal strict a été établi :

$$S(T_{s,f}) \geq 20 \quad (3)$$

Si aucun cadre candidat n'atteint ou ne dépasse ce score seuil, la séquence est rejetée comme « Non-K13 » et exclue du dépistage de mutations en aval. La séquence candidate présentant le score le plus élevé dépassant ce seuil est retenue comme séquence protéique traduite de l'isolat. Tout codon stop terminal est retiré avant l'analyse en aval.

2.6 Cartographie dynamique des coordonnées tenant compte de l'alignement

Pour éviter les erreurs de décalage d'index causées par des troncatures de séquence ou des indels (insertions et délétions) dans les amplicons cliniques, nous avons cartographié les coordonnées de façon dynamique à l'aide des segments d'alignement à score élevé (HSP) de BLAST, plutôt qu'en utilisant des index de chaîne absolus. La séquence requête a été alignée contre la base de données 3D7 à l'aide de BLASTP local, avec un seuil de valeur E de 1×10^{-5} . Les champs de sortie récupérés pour chaque alignement comprenaient les bornes du HSP ($sstart$, $send$, $qstart$, $qend$), ainsi que la chaîne requête alignée ($qseq$) et la chaîne de référence sujet ($sseq$).

Pour chaque coordonnée de résistance validée par l'OMS P_{ref} , le pipeline vérifie si $sstart \leq P_{\text{ref}} \leq send$. Si P_{ref} se situe hors de cet intervalle, la position est marquée comme « non couverte » par l'amplicon séquencé. Si elle est couverte, l'algorithme parcourt de façon synchrone $qseq$ et $sseq$ pour identifier le résidu observé et détecter d'éventuels changements non synonymes, sans hypothèse de référence absolue.




Figure 1: Organigramme architectural du pipeline de parcours de coordonnées et de dépistage des mutations. L'entrée FASTA brute est traduite dans les six cadres de lecture, notée par rapport à la référence 3D7 via la correspondance de peptides 5-mer, puis soit rejetée (score < 20), soit transmise à l'alignement BLASTP. Le parcours de coordonnées tenant compte de l'alignement cartographie ensuite les neuf positions K13 validées par l'OMS sur la séquence requête, avant la génération finale du rapport.

2.7 Génération automatisée de rapports multi-formats

À l'issue du dépistage, les résultats ont été agrégés en deux formats de sortie : (i) un fichier CSV exploitable par machine pour les calculs épidémiologiques et statistiques, et (ii) un tableau de bord HTML autonome et adaptatif, stylisé en CSS. Ce tableau de bord comprend des cartes visuelles mettant en évidence les statistiques globales (nombre total dépisté, nombre de résistants, répartition par pays), des tableaux de résultats par isolat affichant le pourcentage d'identité, la valeur E et le statut de résistance, ainsi qu'un résumé des isolats par pays.

2.8 Disponibilité du code et des données

Le pipeline Python complet et documenté, les scripts de validation, les jeux de référence synthétiques et les cohortes FASTA cliniques sont open-source et hébergés publiquement sur GitHub à l'adresse : <https://github.com/ShegouB/artemisinin-resistance>, afin de faciliter l'audit externe et la validation indépendante.

3. Résultats

3.1 Vérification de la séquence de référence

La séquence de référence récupérée (XP_001350158.1) a été correctement analysée et vérifiée comme comptant exactement 726 acides aminés, en accord avec la longueur annotée de la séquence complète de K13 chez 3D7. La base de données BLAST locale a été construite sans avertissement ni erreur.

3.2 Performance du pipeline sur le panel simulé (validation interne)

Le pipeline a traité avec succès les 30 isolats synthétiques. Les alignements contre la référence ont donné une identité de 100,0 % pour les 23 séquences sauvages, et une identité de 99,86 % (correspondant à un seul mésappariement sur 726 résidus) pour les 7 séquences mutantes, avec des valeurs E d'environ 0,0 dans tous les cas.

La comparaison avec le fichier de vérité terrain masqué a démontré une concordance de 100 % (30/30 isolats correctement classés). Les 7 mutants (porteurs des allèles simulés R539T, Y493H, P553L et I543T) ont tous été correctement détectés, sans aucun faux positif ni faux négatif, soit une sensibilité et une spécificité de 100,0 %.

3.3 Performance du pipeline sur le panel clinique multi-pays ouest-africain

Le pipeline a aligné et analysé les 66 séquences cliniques réelles récupérées depuis GenBank en 2,1 secondes sur un ordinateur de bureau bicœur standard. L'heuristique de traduction à 6 cadres et 5-mers a résolu avec succès les anomalies de décalage de phase et de brin inverse. Fait notable, les 15 séquences ghanéennes (OQ102653–OQ102667) — qui échouaient initialement à s'aligner en raison d'un séquençage en brin inverse — ont été correctement inversées-complémentées et traduites, avec des identités BLASTP allant de 93,7 % à 100,0 % et des valeurs E aussi faibles que $9,45 \times 10^{-109}$. Les amplicons

nigériens MT113570 et MT113571 ont été traduits hors cadre, obtenant des alignements valides avec des identités de 97,85 % et 99,27 % respectivement. Aucune donnée non résolue (N/A) n'est demeurée dans les rapports finaux.

Table 2: Résumé de l'origine géographique de la cohorte clinique et des métriques d'alignement.

Pays	Série d'accessions	Isolats (n)	Longueur (aa)	Identité BLASTP (%)	Plage de valeur E
Bénin	MN072940– MN072959	20	213	96,2–100,0	0,0 à $5,67 \times 10^{-155}$
Ghana	OQ102653– OQ102667	15	145–150	93,7–100,0	$9,45 \times 10^{-109}$ à $2,23 \times 10^{-109}$
Niger	MZ364160– MZ364174	15	273	98,9–100,0	0,0
Nigeria	MT113570– MT113584	15	269–283	95,8–100,0	0,0
Sénégal	MH464876	1	269	91,8	0,0

3.4 Détection automatisée d'une mutation de résistance validée dans un isolat ghanéen

Sur les 66 séquences ouest-africaines réelles, le pipeline en a classé 65 comme sauvages et a identifié exactement un isolat clinique résistant. Cette séquence clinique portait une seule mutation non synonyme, Y493H, au sein du domaine propeller. La comparaison avec la littérature publiée pour l'accession GenBank OQ102665 (Dieng et al., 2023) a confirmé une concordance de 100 %, les auteurs ayant rapporté ce même mutant Y493H unique dans le nord du Ghana [5]. Tous les autres isolats cliniques du Nigeria, du Niger, du Bénin et du Sénégal ont été correctement classés comme sauvages, soit une concordance de validation de 100,0 % (66/66) sur le panel clinique.

3.5 Vitesse de traitement et empreinte des ressources

L'utilisation de la mémoire durant les phases de chargement de la base de données et d'alignement BLASTP a atteint un pic de 48 Mo de RAM, largement compatible avec la capacité de systèmes informatiques à ressources limitées. L'exécution complète du pipeline s'est achevée en moins de 3 secondes, ce qui le rend adapté à une surveillance de routine par lots sur le terrain.

4. Discussion

4.1 Surmonter les défis de décalage de cadre et de brin inverse

Le principal résultat technique de cette étude est le succès de l'heuristique de traduction à 6 cadres avec score de correspondance de peptides 5-mer. Les pipelines classiques de correspondance de séquences supposent des séquences d'acides aminés propres, dans

le bon cadre et de pleine longueur, ce qui est rarement le cas pour un séquençage de terrain de routine. Les séquences Sanger d'amplicons K13 sont fréquemment tronquées et souvent générées à l'aide d'amorces de séquençage inverses, ce qui signifie qu'elles sont stockées dans les bases de données publiques sous forme de nucléotides inverses-complémentaires par rapport au brin codant.

Tenter de traduire ces séquences inverses-complémentaires dans les trois cadres de lecture directs standards produit des traductions inutilisables comportant de multiples codons stop, ce qui empêche BLAST d'aligner les séquences (renvoyant des valeurs N/A). En testant à la fois les brins direct et inverse-complémentaire dans les trois cadres de lecture possibles, et en utilisant un système de score par correspondance de peptides 5-mer par rapport à la référence, notre pipeline a résolu avec succès ces artefacts de séquençage. L'alignement et la cartographie réussis des 15 séquences ghanéennes — qui échouaient initialement à s'aligner — démontrent l'utilité de cette heuristique pour des séquences FASTA consensus de terrain non curées.

4.2 Utilité pour une surveillance locale et hors ligne

La plupart des plateformes de surveillance moléculaire existantes reposent sur le web et nécessitent une connexion internet stable à haut débit pour téléverser et aligner les données de séquence. Bien que précieuses, ces plateformes sont peu adaptées à une surveillance locale de routine dans les régions ouest-africaines isolées, où la connectivité internet est instable. Notre pipeline a été conçu comme un outil « offline-first », ne nécessitant qu'une configuration ponctuelle d'un environnement scientifique Python standard et de la suite BLAST+ locale. Une fois configurés, la construction de la base de données de référence, le parcours de coordonnées tenant compte de l'alignement et la génération de rapports HTML stylisés s'effectuent entièrement en local et hors ligne, offrant une solution accessible aux laboratoires de référence régionaux du Bénin et des pays voisins.

4.3 Portée de la validation et concordance épidémiologique

La stratégie de double validation adoptée dans cette étude représente une approche rigoureuse pour évaluer des outils bioinformatiques avant leur déploiement. En utilisant un panel simulé (validation interne), nous avons démontré que la logique sous-jacente de détection des mutations atteint une sensibilité de 100 % pour la détection des mutations de résistance validées (F446I, N458Y, M476I, Y493H, R539T, I543T, P553L, R561H, C580Y).

En évaluant le pipeline sur une cohorte clinique géographiquement diversifiée de 66 séquences réelles du Bénin, du Niger, du Nigeria, du Ghana et du Sénégal, nous avons démontré une spécificité clinique élevée. Le pipeline a classé 65 séquences comme sauvages et a signalé avec succès l'unique mutant Y493H authentique (accession OQ102665) du nord du Ghana. Cette découverte revêt une importance clinique significative. La substitution Y493H est un marqueur validé par l'OMS, fortement associé à une résistance de haut niveau à l'artémisinine en Asie du Sud-Est [1]. Sa présence dans le nord du Ghana (telle que documentée par Dieng et al., 2023 [5]) constitue un signal d'alerte précoce critique pour la surveillance en Afrique de l'Ouest.

4.4 Dissociation du suivi des séquences par parcours de coordonnées

Les scripts de dépistage classiques reposent sur des expressions régulières rigides (regex) ou une correspondance exacte de sous-chaînes pour localiser les mutations. Cela constitue un point de défaillance majeur, car tout indel (insertion ou délétion) ou tout désaccord dans la séquence flanquante décale l'index cible, provoquant des faux négatifs ou des plantages de script. En utilisant notre algorithme de « parcours de coordonnées » tenant compte de l'alignement, le pipeline suit dynamiquement les index de référence du sujet à travers les lacunes (caractères « - ») et les correspondances de l'alignement BLASTP. La dissociation de l'indexation des coordonnées par rapport à la longueur brute de la chaîne requête permet au pipeline de s'adapter aux insertions, délétions et troncatures. Cela constitue un avantage considérable par rapport aux méthodes fondées sur les regex, garantissant une performance robuste sur des lectures Sanger imparfaites.

4.5 Limites techniques et perspectives de recherche

Malgré sa performance robuste, plusieurs limites de l'actuel pipeline doivent être notées : (i) *Analyse au niveau protéique uniquement* : le pipeline opère sur des séquences protéiques traduites et ne peut pas traiter les lectures nucléotidiques courtes brutes non alignées (FASTQ) générées par les plateformes de séquençage à haut débit (NGS). (ii) *Dépendance aux tables de référence des mutations validées par l'OMS* : le module de dépistage spécifique aux positions ne cible que les neuf marqueurs de résistance validés par l'OMS. (iii) *Absence de gestion des infections mixtes* : le pipeline évaluant des séquences consensus uniques, il ne peut pas résoudre les infections à clones mixtes comportant à la fois des populations parasitaires sauvages et mutantes.

5. Conclusion

Nous avons développé et validé un pipeline léger, open-source et fondé sur BLASTP, destiné au dépistage des séquences du domaine propeller de kelch13 chez *P. falciparum* pour la détection de mutations de résistance à l'artémisinine. En s'appuyant sur une heuristique de traduction à 6 cadres et une cartographie de coordonnées tenant compte de l'alignement, le pipeline résout les artefacts de séquençage courants, tels que les troncatures de séquence et les lectures inverses-complémentaires, sans curation manuelle. Un protocole de double validation a démontré une sensibilité de 100 % sur un jeu de données simulé de 30 isolats, et une spécificité de 100 % sur une cohorte clinique géographiquement diversifiée de 66 séquences ouest-africaines réelles du Bénin, du Niger, du Nigeria, du Ghana et du Sénégal. Cet outil léger fournit une solution accessible et robuste pour la surveillance moléculaire locale de la résistance aux antipaludiques au Bénin et dans l'ensemble de la région ouest-africaine.

References

- [1] Arieu, F. et al. (2014). A molecular marker of artemisinin-resistant *Plasmodium falciparum* malaria. *Nature*, 505(7481), 50–55. <https://doi.org/10.1038/nature12876>

- [2] Ashley, E. A. et al. (2014). Spread of artemisinin resistance in *Plasmodium falciparum* malaria. *NEJM*, 371(5), 411–423. <https://doi.org/10.1056/NEJMoa1314981>
- [3] Uwimana, A. et al. (2020). Emergence and clonal expansion of *in vitro* artemisinin-resistant *Plasmodium falciparum* kelch13 R561H mutant parasites in Rwanda. *Nature Medicine*, 26(10), 1602–1608. <https://doi.org/10.1038/s41591-020-1005-2>
- [4] MalariaGEN, Ahouidi, A. et al. (2021). An open dataset of *Plasmodium falciparum* genome variation in 7,000 worldwide samples. *Wellcome Open Research*, 6, 42. <https://doi.org/10.12688/wellcomeopenres.16168.1>
- [5] Dieng, C. C. et al. (2023). Distribution of *Plasmodium falciparum* K13 gene polymorphisms across transmission settings in Ghana. *BMC Infectious Diseases*, 23(1), 801. <https://doi.org/10.1186/s12879-023-08812-w>
- [6] Ajogbasile, F. V. et al. (2022). Molecular profiling of the artemisinin resistance Kelch 13 gene in *Plasmodium falciparum* from Nigeria. *PLOS One*, 17(2), e0264548. <https://doi.org/10.1371/journal.pone.0264548>
- [7] Arzika, I. I., Lamine, M. M., Ibrahim, M. L., ... Lobo, N. F. (2023). *Plasmodium falciparum* kelch13 polymorphisms identified after treatment failure with artemisinin-based combination therapy in Niger. *Malaria Journal*, 22, 142. <https://doi.org/10.1186/s12936-023-04571-w>
- [8] Schmedes, S. et al. (2021). *Plasmodium falciparum* kelch13 Mutations, 9 Countries in Africa, 2014–2018. *Emerging Infectious Diseases*, 27(7), 1902–1908. <https://doi.org/10.3201/eid2707.203230>